Big Data

Trabajo Práctico Nº1

Otoño 2026

Lucas Gael Chandia, Mateo Lopez Olaciregui y María Sol Sampogna Espíndola

Fecha de entrega: 27 de Marzo de 2027

Parte I: Familiarizandonos con la base EPH y limpieza

Ejercicio 1

Las unidades económicas que producen bienes o servicios para el mercado y no están reconocidas formalmente como tales componen el sector informal (INDEC, 2025). En este marco, la informalidad laboral se define como un fenómeno heterogéneo que abarca a trabajadores y unidades productivas que operan al margen de las normas laborales y tributarias.

Siguiendo el enfoque de la Organización Internacional del Trabajo (OIT), el INDEC distingue entre sector formal, sector informal y sector hogares, según el destino de la producción y el grado de reconocimiento de las unidades económicas.

En la Encuesta Permanente de Hogares (EPH), la identificación de la informalidad laboral se realiza a partir de variables vinculadas al cumplimiento de la normativa laboral en el puesto de trabajo principal. En particular, para los trabajadores asalariados, el criterio central es la ausencia de aportes a la seguridad social (es decir, la falta de descuento jubilatorio), lo que permite clasificarlos como informales. En el caso de los trabajadores independientes, se considera su grado de registro y el cumplimiento de obligaciones fiscales.

Ejercicio 2

a):

La región seleccionada para este trabajo práctico fue la de Cuyo específicamente.

b):

Las variables seleccionadas para nuestro grupo, además de las que obligatoriamente teníamos que incluir, fueron: CH14, CH15_COD, CH16_COD, PP03C, PP04B_COD, PP06H y PP07A.

c):

Para poder darnos cuenta de que fallas podrían estar teniendo las variables, utilizamos los diccionarios como referencia.

Por un lado, desde inciso b) mediante la verificación del formato de los valores nos pudimos dar cuentas de algunas inconsistencias de las variables utilizadas. En el caso de la variable que engloba cuantos años cumplidos tiene, esta empezaba desde el -1, cosa que no tiene mucho sentido.

Por otro lado, dado a la información que nos proporciona los diccionarios, los valores de 9, 99, 999 y 9999 significan que allí no contamos con valores, es decir lo que conocemos como Non-Values. Podemos observar que para las variables que engloban el tipo de cobertura médica, el último año que aprobó, cuánto tiempo hace que está trabajando en ese y el monto de ingreso per cápita familiar percibido en el mes de referencia les está pasando que contienen esos números como valores. empleo en forma continua. Por otro lado, se nos indica que el número cero para

las variables es un indicativo de que "no corresponde a la secuencia".

Ahora bien, con esto en mente sobre lo que hay que corregir, redefinimos a las variables con NonValues para cualquiera de los casos mencionados anteriormente, es decir para las variables que al final contienen 9, 99, 9999 o -1.

d):

Dado lo pedido nos arrojo el siguiente gráfico:

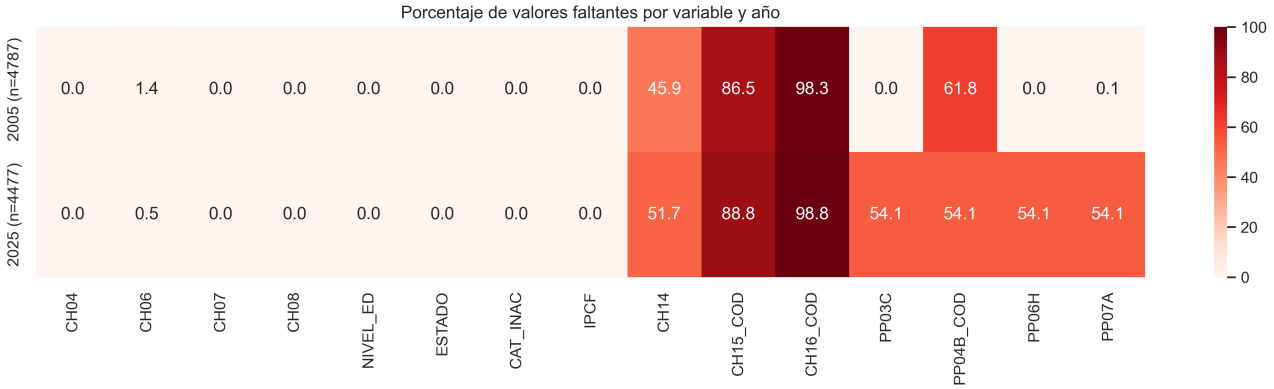

Figure 1: Histograma de valores faltantes por variable y año

Para el gráfico construido, podemos observar que para las variables de CH15_COD y CH16_COD estás dos variables presentan altos porcentajes de NonValues dentro de ellas tanto para 2005 como para 2025.

Las variables CH14 y PP04B_COD presentan entre un 45 y 60% de datos NonValues para los años respectivos años de 2025 y 2005. Mientras que para las variables de PP03C y PP06H y PP07A estas presentan un alto porcentaje para los años de 2025, siendo que como diferencia entre las otras dos solamente en 2005 para PP07A tenemos un 1% de NonValues, es decir casi nada de NonValues.

Parte II: Primer Análisis Exploratorio

Ejercicio 3

Realizando lo pedido llegamos al siguiente gráfico:

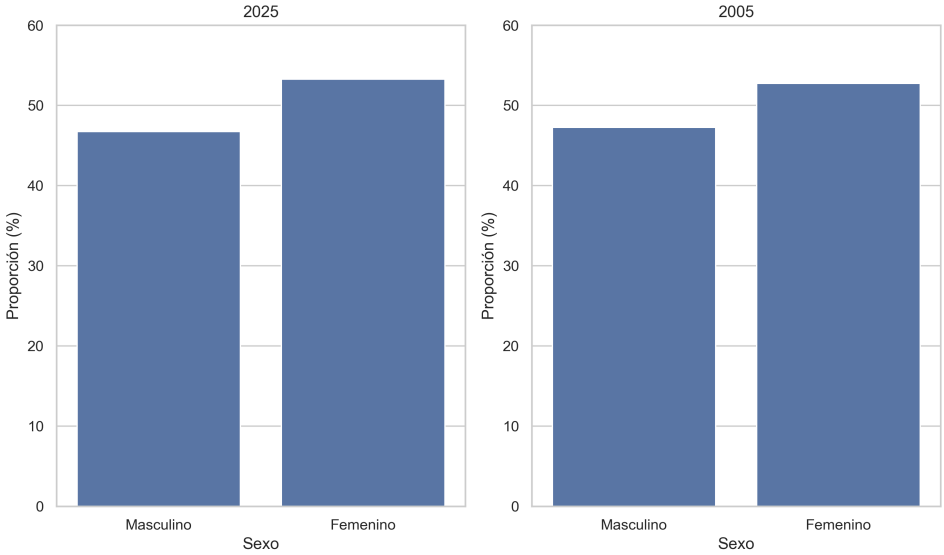

Figure 2: Gráfico de barras que representa masculino y femenino

Podemos observar que para tanto 2005 como para 2025 la proporción entre varones y mujeres se mantiene bastante parecida, siendo que para el de varones este ronde entre un 52% y 53% mientras que para las mujeres ronde entre un 46% y 47%

Ejercicio 4

Dado el gráfico hecho por nuestro grupo, podemos ver que existe una fuerte correlación positiva para ciertos casos en concreto, como con menores de 6 años y la variable de sin instrucción. Luego de manera más leve hay correlaciones fuertes con menor de 10 años y sin instrucción, menor de 6 años y menor de 10 años y estudiante junto a soltero. Ahora con correlación negativa, podemos ver que es muy fuerte para las variables mujer y varón, obra social y sin descuento ni pago. Luego de manera más leve hay una correlación negativa con casado y soltero, ocupado con inactivo y rentista con ocupado. En el resto de cuadrantes hay muy poca correlación, tanto para la negativa como para la positiva.

Siguiendo los pasos del ejercicio llegamos al siguiente gráfico para la matriz de correlaciones de las variables pedidas:

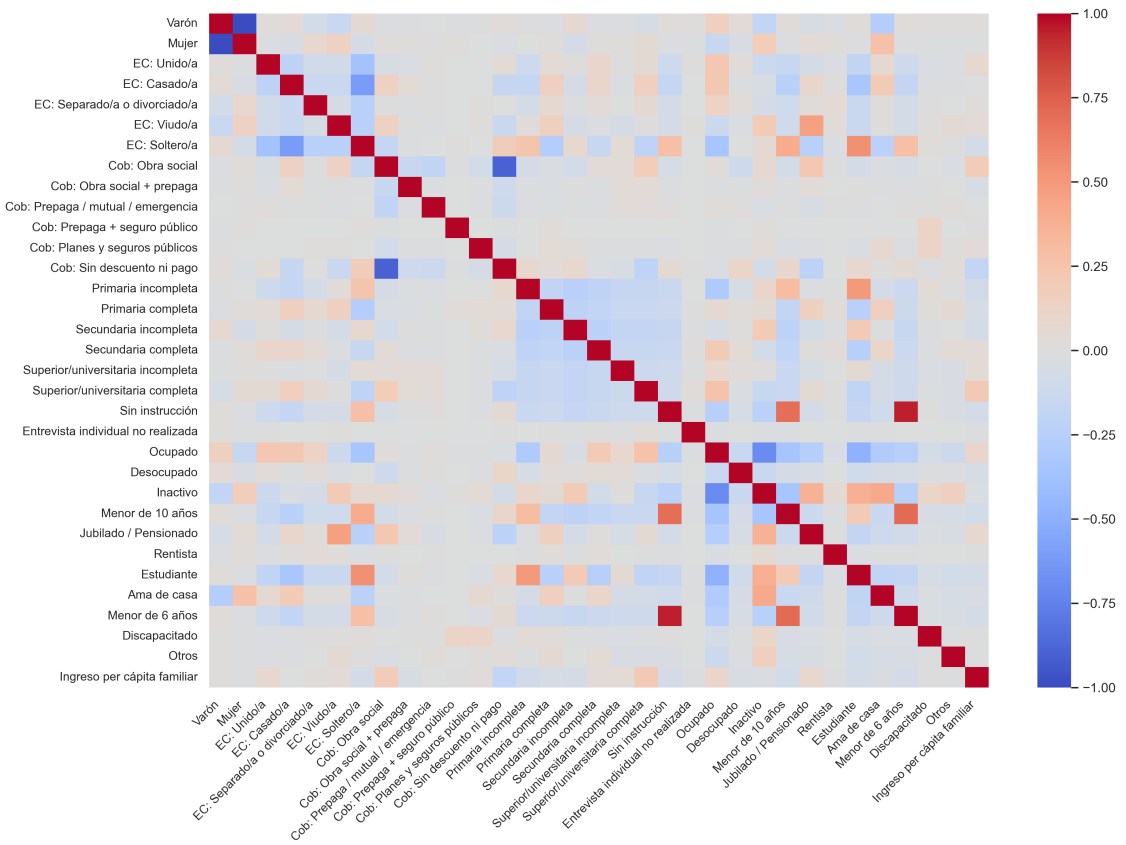

Figure 3: Matriz de correlaciones

Parte III: Conociendo el mercado laboral.

Ejercicio 5

Para poder identificar a las personas que no respondieron su condición de actividad, se utilizó la variable "ESTADO", considerando como no respuesta los casos con valor igual a 0 (ESTADO=0). A partir de esto, se encontró que 6 personas no respondieron dicha pregunta. Luego, se construyeron dos subconjuntos de la base de datos: por un lado, la base denominada *respondieron*, que incluye todas las observaciones con $ESTADO \neq 0$, y por otro, la base *no respondieron*, que incluye las observaciones con $ESTADO = 0$.

Ejercicio 6

Partiendo de la base de personas que respondieron su condición de actividad, se seleccionaron unicamente aquellas clasificadas como $ESTADO = 1$, dado que el análisis de formalidad se aplica unicamente a quienes se encuentran trabajando. La subbase resultante se denominó como *ocupados*. En total, se identificaron un total de 3882 personas ocupadas.

Ejercicio 8

Para la construcción del indicador de informalidad se utilizaron las variables CAT_OCUP y PP07H, siguiendo los criterios definidos en los diccionarios de la EPH. En particular, se consideró como informales a aquellos individuos clasificados como asalariados que no realizan aportes jubilatorios (CAT_OCUP = 3 y PP07H = 2) y a los trabajadores familiares sin remuneración (CAT_OCUP = 4).

A partir de esta definición, se construyó una variable binaria denominada informal, donde el valor 1 indica empleo informal y 0 empleo formal. Asimismo, se excluyeron los casos con respuestas no válidas (Ns/Nr) mediante su recodificación como valores faltantes.

Esta construcción permite aproximar la informalidad laboral a partir de información disponible en la encuesta, aunque puede diferir de la medición oficial, ya que no incorpora todos los criterios utilizados por el INDEC.

Ejercicio 9

En esta sección se analizan las diferencias entre trabajadores formales e informales para los años 2005 y 2025, utilizando estadísticas descriptivas y gráficos exploratorios.

Se observa que los trabajadores informales presentan, en promedio, menores niveles de ingreso, menor edad y menor nivel educativo en comparación con los trabajadores formales. Estas diferencias se mantienen en ambos años analizados, lo que sugiere una segmentación persistente en el mercado laboral.

Asimismo, la composición por sexo muestra ciertas diferencias entre ambos grupos, reflejando que la informalidad tiende a concentrarse en perfiles más vulnerables.

0.1 Gráficos exploratorios

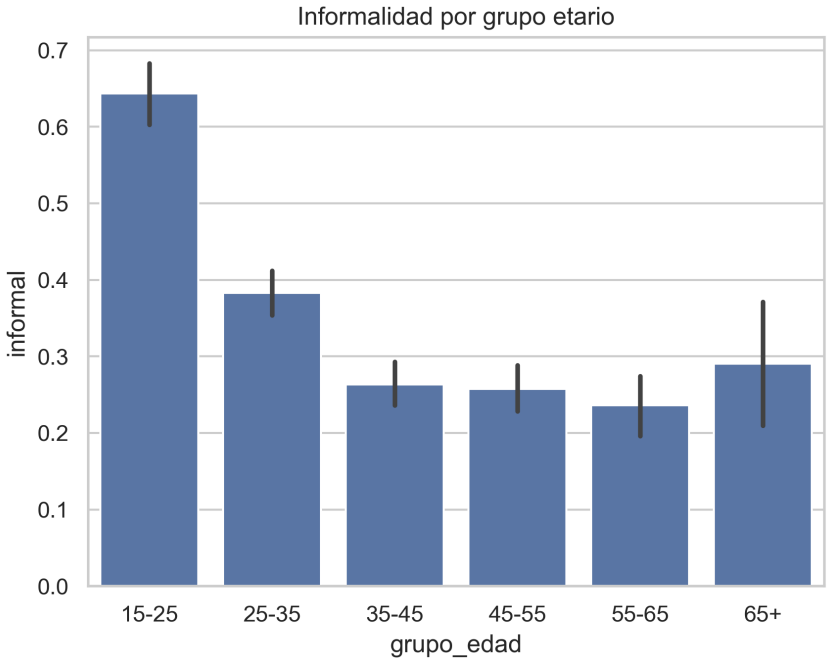

Figure 4: Tasa de informalidad por grupo etario

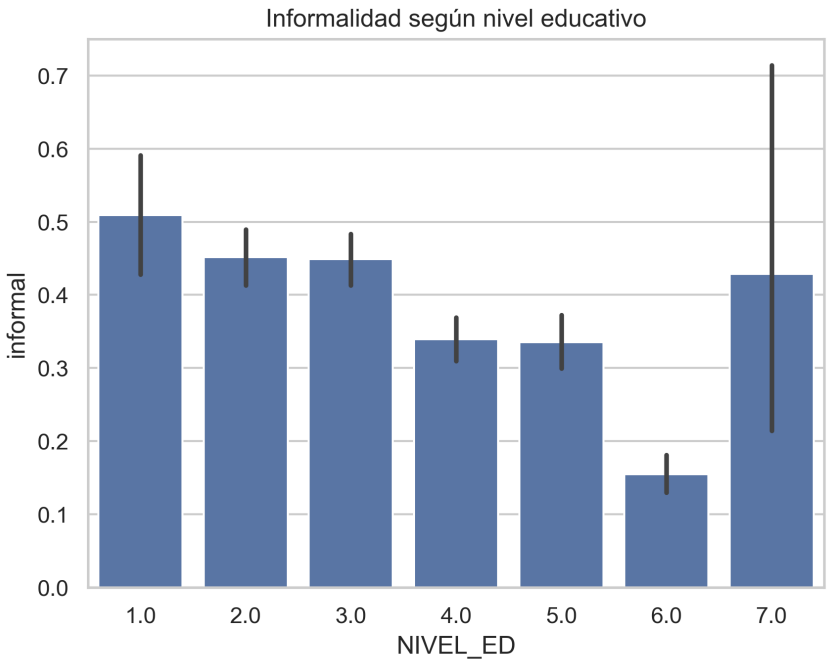

Figure 5: Tasa de informalidad según nivel educativo

Los gráficos muestran que la informalidad es significativamente mayor en los grupos etarios más jóvenes, especialmente entre los 15 y 25 años, lo que sugiere dificultades de inserción laboral

en empleos formales al inicio de la vida laboral. A medida que aumenta la edad, la tasa de informalidad disminuye, aunque se observa un leve repunte en edades más avanzadas.

En cuanto al nivel educativo, se evidencia una relación inversa entre educación e informalidad: a mayor nivel educativo, menor probabilidad de empleo informal. Esto refuerza la idea de que la educación actúa como un factor protector frente a la informalidad laboral.

En conjunto, los resultados indican que la informalidad laboral en Argentina se encuentra fuertemente asociada a menores niveles de capital humano y a etapas iniciales del ciclo de vida laboral. A pesar del paso del tiempo entre 2005 y 2025, estas brechas no muestran cambios sustanciales, lo que sugiere que la informalidad continúa siendo un fenómeno estructural del mercado de trabajo.

Parte IV: Herramientas de IA y reflexión final.

Ejercicio 1

A continuación, mostrare los promts utilizados para el trabajo a forma de ayuda:

ChatGPT:

"a que se refiere con esto? Son non values?"

"respecto a la compación por sexo para 2005 y 2025, qué sería lo que tengo que mostrar? la cantidad o porcentajes de la población para el sexo masculino o feminino?"

"estoy tratando de armar un gráfico de barrar para tener las proporciones del sexo masculino y femenino en dos gráficos distintos para 2005 y 2025. Estaba siguiendo un ejemplo que nos dieron pero me está tirando el siguiente error, será porque para data unicamente funciona con dataframes? en caso de que sea así como hago para representarlo con las variables que cree (sexo_2025 y sexo_2005)? Acá esta mi código: ..."

"me está largando este error el código de la imagen. Estoy trabajando en jupyter notebook"

"me está quedando un mapa bastante feo con las etiquetas, hay alguna forma de mejorarlo para que no sea todo texto?"

"estoy necesitando crear variables dicotómicas binarias (variables dummies). No se si una opcion sería crear un diccionario que contenga en 0 y 1 cada categoría de la variable original, porque las que me de dan están categorizadas de distinta manera, por ejemplo para CH04 el masculino se categoriza con 1 y para el femenino con 2. Esto es para luego armar una matriz de correlación con más variables que tienen el mismo problema exepto una que es númerica. Indicame si lo que pienso es correcto o debería ser de otra forma"

Claude:

"ahora me salto esto en el siguiente bloque, es normal?"

"El código sigue de la siguiente forma, no tuve problema al correr esto. Tengo que continuar con el ejercicio 2b) del pdf que te di ahora. Indicame bien que está pidiendome."

"Realice el ejercicio d) el heatmap que me están pidiendo para analizar, pero está un poco confuso interpretar que está pasando, como se podría mejorar? Acá está el código hecho hasta ahora:

import matplotlib.pyplot as plt plt.figure(figsize=(10,5)) sns.heatmap(df.isnull(), cbar=False) plt.title("Mapa de valores faltantes") plt.show()"

"para el ejercicio 4 no estoy entendiendo si la matriz de correlación es para todas las variables mencionadas en el ejercicio o en pares"

Ejercicio 2

La utilización de las inteligencias artificiales nos ayudo para tanto errores que fueran surgiendo sobre la marcha a la hora de realizar el código, como también para el entendimiento correcto de los ejercicios a la hora de querer empezar a trabajar. Facilito también para entender que fallos estábamos realizando a la hora de crear el código.

Ejercicio 3

En el caso de Lucas, el tiempo que le llevo realizar sus partes fue de entre 6 y 7 horas.

En el caso de Sol, el tiempo que le llevó realizar sus partes fueron aproximadamente 6 horas.

Y por último Mateo le llevo entre 4 y 5 horas.

Bibliografía

INDEC. (2025). Diseño conceptual y metodológico para la medición de la informalidad laboral con datos de la EPH (Metodología INDEC N.º 43). Instituto Nacional de Estadística y Censos. https://www.indec.gob.ar/ftp/cuadros/sociedad/metodologia_informalidad_laboral.pdf