Big Data

Trabajo Práctico Nº1

Otoño 2026

Lucas Gael Chandia, Mateo Lopez Olaciregui

Fecha de entrega: 10 de Abril de 2027

Parte I: Creación de variables, histogramas, kernels y resumen de la base de datos final

Ejercicio 1:

Una vez construido la variable edad2 de la forma pedida, llegamos a los siguientes gráficos:

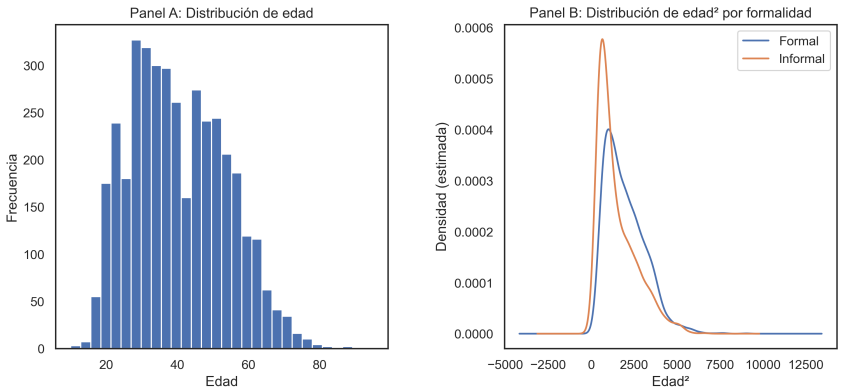

Figure 1: Histograma y Densidad para edad y edad2

En el Panel A presenta una mayor concentración de individuos en edades intermedias (entre aproximadamente 25 y 50 años). La frecuencia disminuye progresivamente hacia edades más altas, lo que genera una leve asimetría hacia la derecha.

En el Panel B, ambas distribuciones muestran formas similares, aunque con diferencias en su dispersión y concentración. En particular, la distribución correspondiente a los individuos informales se encuentra más concentrada en valores relativamente bajos de la variable transformada, mientras que la de los formales presenta una mayor dispersión.

Ejercicio 2:

Dada la creación de la variable "educ", realizamos mediante el jupyter notebook la siguiente estadística descriptiva:

Table 1: Estadísticos descriptivos

Estadístico	**Valor**
count	5655.000000
mean	9.571883
std	6.991942
min	0.000000
50%	9.000000
max	99.000000

La variable presenta un total de 5655 observaciones, con una media de 9.57 y una mediana de

9. Esto sugiere una distribución relativamente centrada en valores cercanos a 9.

La desviación estándar es de 6.99, lo que indica una dispersión considerable respecto de la media. Además, el rango es amplio (de 0 a 99), lo que evidencia la presencia de valores extremos.

Ejercicio 3:

Habiendo hecho la actualización de la variable de "ingreso_total_familiar" en la parte de 2005, construimos los siguientes gráficos:

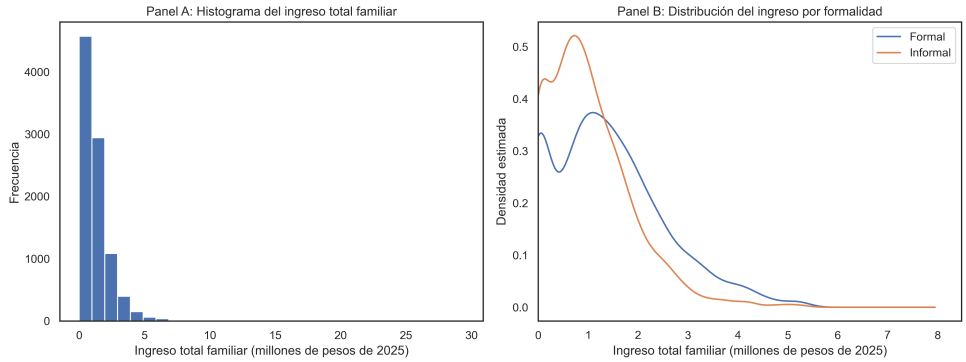

Figure 2: Histograma y Densidad para ingreso familiar y ingreso por formalidad

En el Panel A presenta una fuerte asimetría positiva, con alta concentración de observaciones en niveles bajos de ingreso y una cola larga hacia valores más altos. Esto indica la presencia de pocos casos con ingresos elevados.

En el Panel B, al desagregar por condición de formalidad, se observa que la distribución de los trabajadores formales se desplaza hacia niveles de ingreso más altos en comparación con la de los informales. A su vez, los informales presentan una mayor concentración en los tramos de ingresos más bajos.

Ejercicio 4:

Para la variable llamada "horastrab", realizamos la siguiente estadística descriptiva:

Table 2: Estadísticos descriptivos (horas)

Estadístico	**Valor**
count	2829.000000
mean	26.867444
std	24.763273
min	0.000000
50%	30.000000
max	132.000000

La variable horas trabajadas cuenta con 2829 observaciones, una media de 26.87 y una mediana de 30. La media inferior a la mediana sugiere una leve asimetría hacia la izquierda.

La desviación estándar es elevada (24.76), lo que indica alta dispersión. Asimismo, el rango entre 0 y 132 horas refleja la existencia de valores extremos en la distribución.

Ejercicio 5:

Table 3: Resumen de la base final para la región Chaco

	2005	**2025**	**Total**
Cantidad observaciones	4787	4477	9264
Cantidad de observaciones con NAs en la variable "Informal"	2959	2423	5382
Cantidad de Informales	677	675	1352
Cantidad de Formales	1151	1379	2530
Cantidad de variables limpias y homogeneizadas	15	15	15

La base final para la región Chaco cuenta con 9264 observaciones totales, distribuidas de manera relativamente equilibrada entre los años 2005 (4787) y 2025 (4477). Se observa una cantidad considerable de valores faltantes en la variable "Informal" (5382 casos), lo que implica una reducción significativa en el número de observaciones utilizables para el análisis. Entre las observaciones válidas, la cantidad de trabajadores formales (2530) supera a la de informales (1352). Finalmente, la base queda conformada por 15 variables limpias y homogeneizadas, lo que permite su utilización consistente en los análisis posteriores.

Parte II: Métodos No Supervisados

Ejercicio 1:

Realizamos la siguiente matriz de correlaciones:

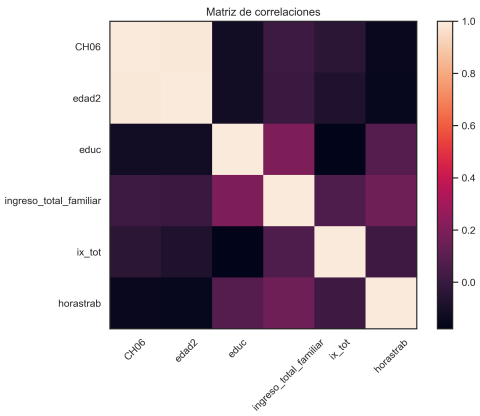

Figure 3: Matriz de correlación

La matriz de correlaciones muestra una relación positiva muy alta entre edad (CH06) y edad², lo cual es esperable dado que una es transformación de la otra. En general, las correlaciones entre las demás variables son bajas, lo que indica que no existe una relación lineal fuerte entre ellas. Se observa una correlación positiva moderada entre educación e ingreso total familiar, así como entre ingreso y horas trabajadas.

Por otro lado, la edad presenta correlaciones débiles con el resto de las variables, mientras que el tamaño del hogar (ix_tot) muestra relaciones muy bajas en general.

En conjunto, la matriz sugiere que no hay problemas severos de multicolinealidad, más allá de la relación esperada entre edad y edad².

Análisis de Componentes Principales (PCA)

Se aplicó el método de Análisis de Componentes Principales (PCA) sobre las variables seleccionadas, previamente estandarizadas, con el objetivo de reducir la dimensionalidad del conjunto de datos y analizar su estructura subyacente.

Ejercicio 2:

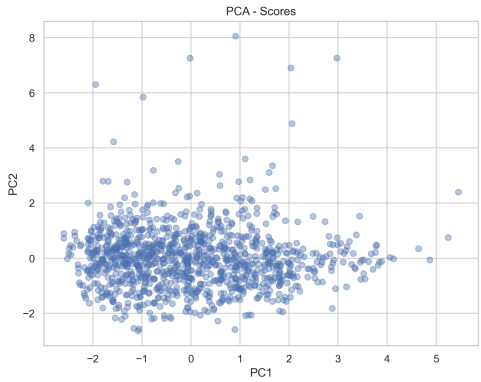

Figure 4: Dispersión de las observaciones en el espacio definido por el primer y segundo componente principal

El primer componente explica la mayor variabilidad y el segundo aporta información adicional. No se observan grupos definidos, lo que sugiere una estructura continua y permite reducir la dimensionalidad.

Ejercicio 3:

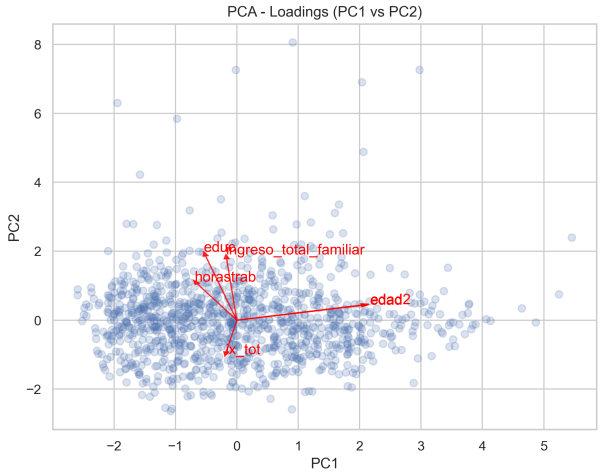

Figure 5: Loadings del PCA para los dos primeros componentes principales

El gráfico de loadings indica que edad2 domina el primer componente, mientras que ingreso_total_familiar y educ definen una dimensión socioeconómica. En conjunto, el PCA identifica dos ejes principales: edad y nivel socioeconómico.

Ejercicio 4:

A continuación, se presenta la proporción de la varianza total explicada por cada uno de los seis componentes principales obtenidos mediante PCA.

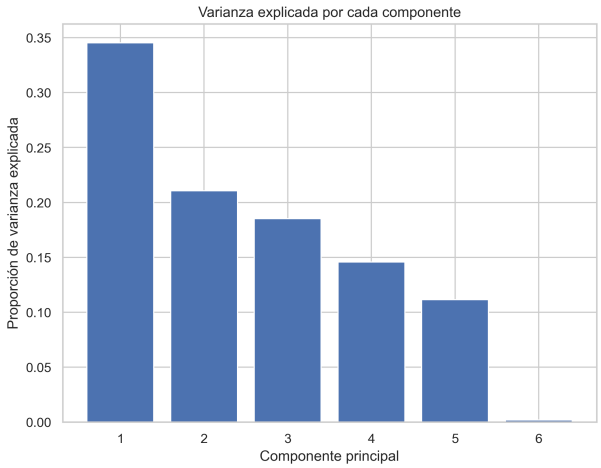

Figure 6: Proporción de la varianza explicada por cada componente principal

Los primeros dos componentes concentran la mayor parte de la varianza, mientras que los restantes aportan poco, lo que permite reducir la dimensionalidad sin pérdida significativa de información.

Ejercicio 5:

a)

Para el método de k-medias, al utilizar k = 2, k = 4 y k = 10 llegamos a los siguientes gráficos:

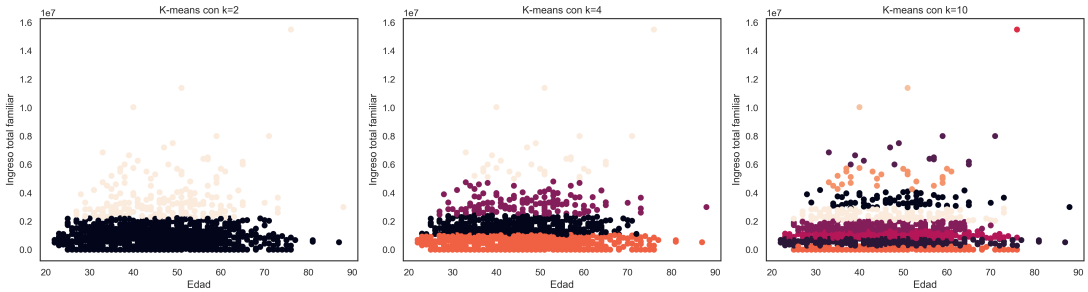

Figure 7: Cluster con k-medias

Con k=2, el algoritmo divide principalmente entre observaciones de ingresos bajos y observaciones de ingresos más altos, más que entre grupos etarios. Al aumentar a k=4 y k=10, la partición se vuelve más detallada y aparecen subgrupos dentro de distintos rangos de ingreso, mientras que la edad no parece ser la variable que más ordena la separación. En conclusión, k=2 no separa correctamente a trabajadores formales e informales, ya que los clusters se forman sobre todo según similitudes en el ingreso y no según la condición de formalidad.

b)

Realizando el metodo de Elbow, llegamos al siguiente gráfico para representar que k ajusta mejor:

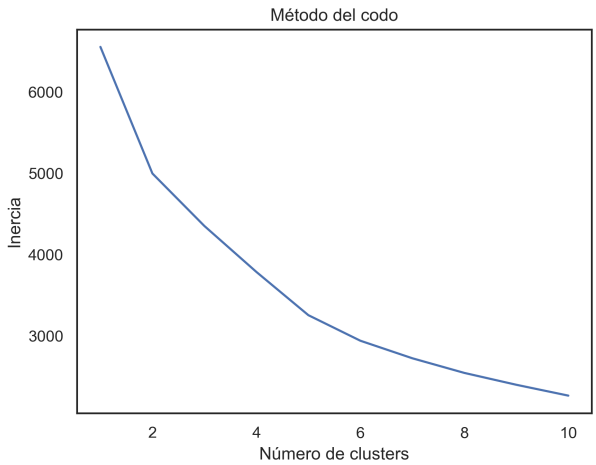

Figure 8: Metodo de Elbow

Se observa que la reducción en la disimilitud es pronunciada hasta aproximadamente k=4, a partir de donde la mejora se vuelve más gradual. Esto sugiere que el número óptimo de clusters

es cercano a k=4. Esta cantidad de grupos permite capturar parte de la heterogeneidad de los datos, aunque no necesariamente distingue de forma clara entre trabajadores formales e informales, sino entre distintos perfiles según edad, ingreso y otras variables.

Ejercicio 6:

Realizamos un clúster jerárquico para las variables de arriba y llegamos al siguiente gráfico:

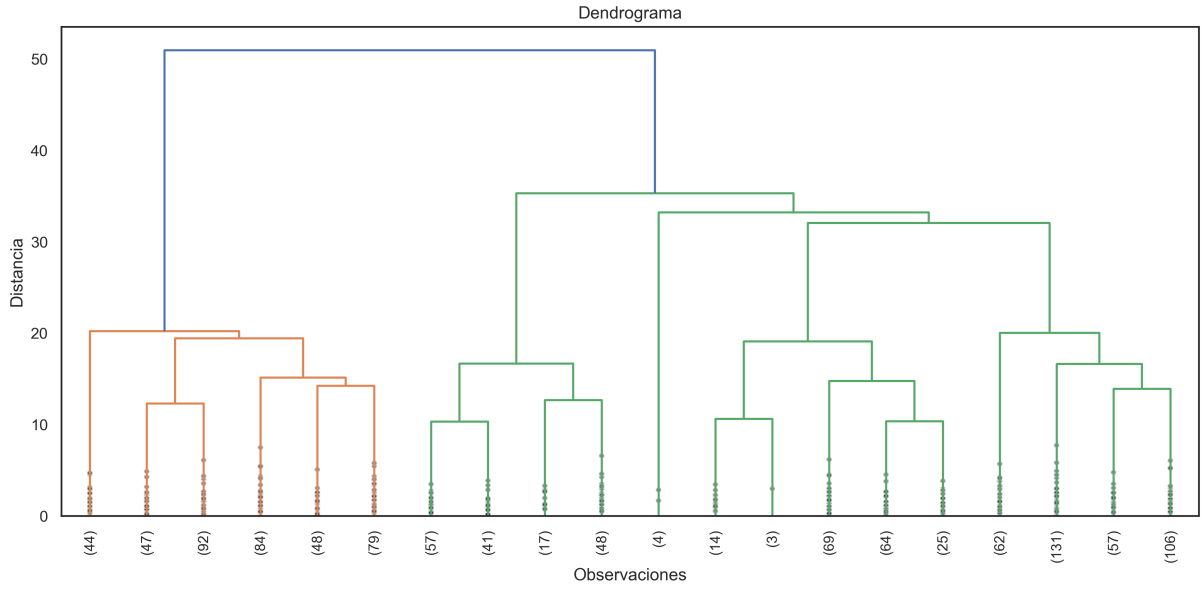

Figure 9: Dendrograma

Un clúster jerárquico nos sirve para solucionar el problema típico de no saber como definir el numero de grupos para separar las variables agrupando según su similitud en este caso. Para ello, esta la herramienta gráfica del dendrograma. En el eje vertical se representa la distancia o disimilitud entre los grupos, mientras que en el eje horizontal se ubican las observaciones.

En el dendrograma, las observaciones que se unen a menor altura son más similares entre sí, mientras que aquellas que se conectan a mayor altura presentan mayor diferencia. A medida que se asciende en el gráfico, los clusters se van fusionando hasta conformar un único grupo.

La ventaja de este método es que nos permite visualizar distintas posibles particiones de los datos, determinando con una linea recta horizontal la cantidad de grupos que uno quiere según el nivel de disimilitud que quiere.

Parte IV: Herramientas de IA y reflexión final

Ejercicio 1:

ChatGPT:

"tomo el ipc de que mes? porque no estoy encontrando anual"

"el ejercicio 4) seria simplemente sumar las variables?"

"tuve un problema con la subida de unos archivos al repositorio, es como que no me subio los archivos bien al repositorio porque están vacios. Lo raro es que no me debería haber podido funcionar todo lo que hice si las bases estan mal, pero es verdad que es tan vacias. Si te fijas los tamaños de los archivos no son iguales (los de Individual_t305 y usu_individual_T325, el otro está bien el que se llama base_con_informal que la cree yo). Necesito que esten subidas bien y borrar las otras que están vacias"

"la mediana es el promedio? digo por el que me pide en el ejercicio 2 también"

"ayudame con el ejercicio 5a) sobre clusters"

"para ver el tamaño de la base de datos como me pide en el ejercicio 5), me conviene hacer un append de las variables que use/contrui en dataframe nuevo o por ejemplo lo puedo hacer en el df que tenía previamente?"

Cloude:

"Me tiro un error, decime que esta pasando, te paso el código completo: ..."

"me tira este error"

Ejercicio 2:

Tanto como en el primer trabajo práctico, la ia nos ayudo para corregir códigos o errores que nos podrían ir apareciendo que no observamos nosotros. También como ayuda para cosas que nos pasaron dentro del github. Al mismo tiempo, nos facilito para interpretar correctamente un ejercicio en caso de no entender si es de cierta manera u otra. Si tuviéramos que especificar alguna parte donde nos ayudo más, podríamos decir que fue para la primera parte.

Ejercicio 3:

Para este trabajo práctico, nos llevo en total unas 15 horas completar el trabajo.

Bibliografía

INDEC. (2025). Diseño conceptual y metodológico para la medición de la informalidad laboral con datos de la EPH (Metodología INDEC N.º 43). Instituto Nacional de Estadística y Censos. https://www.indec.gob.ar/ftp/cuadros/sociedad/metodologia_informalidad_laboral.pdf

Calculadora de inflación. (s.f.). Inflación en Argentina.
Recuperado de https://calculadoradeinflacion.com/argentina.html