



Universidad de
SanAndrés

Big Data

Trabajo Práctico N°3

Otoño 2026

Lucas Gael Chandia, Mateo Lopez Olaciregui

Fecha de entrega: 15 de Mayo de 2026

A. Enfoque de validación

2)

Table 1: Comparación de medias entre 2005 y 2025

Variable	Media 2005	Media 2025	Diferencia	p-value
CH06	39.36	41.11	1.76	4.20e-05
edad2	1727.74	1869.91	142.18	1.40e-04
educ	10.28	11.99	1.71	1.91e-39
ingreso_total_familiar	1,416,588	1,297,905	-118,682.85	5.00e-03
horastrab	43.63	37.96	-5.67	1.37e-10
ix_tot	4.40	3.68	-0.72	1.92e-32

Observando las tablas, se puede ver diferencias estadísticamente significativas en todas las variables consideradas, ya que en todos los casos los valores p son inferiores a 0,01. Esto permite rechazar la hipótesis nula de igualdad de medias entre ambos años y concluir que la composición de los trabajadores ocupados cambió de manera sustancial entre 2005 y 2025. En conjunto, los resultados muestran que los trabajadores ocupados de 2025 son, en promedio, mayores, más educados, viven en hogares más pequeños y trabajan menos horas que los de 2005.

B. Modelo de Regresión Logística

1)

Table 2: Coeficientes y odds ratios del modelo logístico para 2025 y 2005

Predictor	Coeficiente 2025	Odds ratio 2025	Coeficiente 2005	Odds ratio 2005
Constante	0.8259	2.2840	0.0218	1.0221
edad2	-0.0004	0.9996	0.0001	1.0001
educ	-0.0951	0.9092	-0.0161	0.9840
ingreso_total_familiar	-0.0000	1.0000	-0.0000	1.0000
horastrab	-0.0178	0.9824	-0.0108	0.9892
ix_tot	0.0357	1.0363	0.1319	1.1409

En ambos años, los resultados del modelo logístico muestran que la educación y las horas trabajadas se asocian negativamente con la probabilidad de ser informal, mientras que el tamaño del hogar se asocia positivamente.

Las horas trabajadas también presentan un efecto negativo en ambos períodos. Por su parte, la edad y el ingreso total familiar muestran coeficientes muy cercanos a cero, por lo que su impacto marginal sobre la informalidad es prácticamente nulo.

2)




Figure 1: Probabilidad predicha para 2025




Figure 2: Probabilidad predicha para 2005

La Figura 1 muestra que, para 2025, la probabilidad predicha de ser informal disminuye de manera marcada a medida que aumentan los años de educación. Esto sugiere que la educación actúa como un factor protector importante frente a la informalidad laboral. En la Figura 2, correspondiente a 2005, también se observa una relación negativa entre educación e informalidad, aunque mucho más tenue.

En conjunto, los gráficos indican que la educación reduce la probabilidad de empleo informal en ambos años, pero su efecto es considerablemente más fuerte en 2025. Esto es consistente con los resultados del modelo logístico, donde el coeficiente asociado a la variable educ es más negativo en 2025 que en 2005.

C. Método de Vecinos Cercanos (KNN)

3)

En 2005, el accuracy aumenta levemente al pasar de $K=10$ a $K=100$, alcanzando su mejor desempeño con $K=100$. En cambio, en 2025 el mejor resultado se obtiene con $K=10$, mientras que valores más altos de K reducen la precisión del modelo. En general, un valor pequeño de K genera un modelo más flexible y con menor sesgo pero mayor varianza, mientras que un valor grande de K suaviza la frontera de decisión, aumentando el sesgo y reduciendo la varianza.

4)




Figure 3: Visualización de ingreso_total_familiar, ix_tot y los valores predichos

5)




Figure 4: Acurrcy entre modelos

D. Desempeño de modelos, elección y predicción afuera de la muestra

6)




Figure 5: Comparación entre modelos

Ambas curvas se ubican claramente por encima de la diagonal correspondiente a un clasificador aleatorio, lo que indica que los dos modelos tienen capacidad para distinguir entre trabajadores formales e informales.

El área bajo la curva (AUC) es de 0.727 para el modelo Logit y de 0.723 para KNN con K-CV. Estos valores son muy similares, por lo que ambos modelos presentan un desempeño predictivo prácticamente equivalente. En términos generales, un AUC cercano a 0.73 indica una capacidad de discriminación moderada.

Dado que el modelo Logit obtiene un AUC levemente superior y además permite interpretar el efecto de cada variable sobre la probabilidad de informalidad, se considera que ofrece un desempeño marginalmente mejor que KNN para la base de testeo de 2025.

7)

Para identificar trabajadores informales y asignar recursos del programa de formalización laboral, el modelo más conveniente es la Regresión Logística. Si bien ambos modelos presentan un desempeño muy similar, el Logit obtiene un AUC ligeramente superior.

En este contexto, resulta especialmente importante minimizar los falsos negativos, es decir, los casos en que un trabajador informal no es identificado por el modelo y queda excluido del programa. Dado su buen desempeño predictivo y su mayor facilidad de interpretación, el modelo Logit es la alternativa más adecuada para la asignación de recursos públicos.

E. Herramientas de IA y reflexión final

1)

Durante el desarrollo del trabajo practico, la ia nos ayudo más en errores particulares de la construcción de los ejercicios, como lo pueden ser algunos problemas que tuvimos a la hora de importar la base de datos del tp anterior. De la misma forma, nos ayudo para interpretar ejercicios y corregir errores que tuvimos a lo largo del tp.

2)

Aquí ponemos los links de los chats de las ias utilizadas:

<https://claude.ai/share/87152901-5fd9-4f46-a93f-690501366071>

<https://chatgpt.com/share/6a021278-6178-83e9-b82b-9c8daf651ed6>

<https://chatgpt.com/share/6a071899-dd34-83e9-9943-f6490fab3494>

3)

El tiempo que nos llevo aproximadamente fue de 11 horas en total.