



Universidad de
SanAndrés

Big Data

Trabajo Práctico N°4

Otoño 2026

Lucas Gael Chandia, Mateo Lopez Olaciregui

Fecha de entrega: 26 de Mayo de 2026

Dada las correcciones mencionadas en las clases de la materia en esta última semana, mencionamos el proceso de re-selección de variables para la matriz X dada la variable Y como informalidad:

- Primero, como determinante de la informalidad podemos considerar la edad, dado que para ciertas edades resulta más difícil la obtención de ciertos empleos. La variable `edad2` podría estar capturando la relación no lineal entre edad e informalidad. Asimismo, `educ` también puede ser una variable relevante, dado que en muchos casos es lo que determina las posibilidades de trabajo que pueden tener los individuos. Respecto de los ingresos totales familiares, los ingresos bajos podrían estar correlacionados justamente con la informalidad.
- La variable `IX_TOT`, por otro lado, indica la cantidad total de integrantes de la familia, por lo que podría pensarse que hogares más numerosos estarían más presionados a aceptar trabajos más informales. Con `horastrab` podemos observar horarios de trabajo muy bajos o extremadamente altos que podrían estar asociados a trabajos informales. La variable `CH04` podría reflejar una tendencia diferencial en la obtención de empleos informales según el sexo. Por su parte, `PP07H` indica la antigüedad en el trabajo, lo que también podría explicar la informalidad.
- `PP03C` indica la cantidad de ocupaciones que tiene la persona, por lo que podríamos pensar que quienes poseen más trabajos intentan compensar ingresos mediante empleos informales. En el caso de `CAT_OCUP`, esta variable indica la categoría ocupacional de la persona, describiendo el tipo de relación laboral que posee. Finalmente, `CH07` indica el estado civil de la persona, lo cual podría ayudar a identificar si existe alguna tendencia respecto de la búsqueda de empleos más formales.

A. Modelo de Regresión Logística con Regularización: Ridge y LASSO

1. Visualización




Figure 1: Paneles de penalización 2025

Para este caso de 2025, podemos apreciar que, para ambos métodos o técnicas de regularización, a medida que aumenta el parámetro de penalización los coeficientes comienzan a disminuir con respecto al modelo comparativo de MCO. En el caso de Ridge, cuando el penalizador tiende a infinito, los coeficientes tienden a cero, aunque nunca llegan a ser exactamente iguales a cero. En cambio, en el caso de LASSO, los coeficientes sí pueden volverse exactamente cero, funcionando así como un método más selectivo de variables.




Figure 2: Paneles de penalización 2005

Para el caso de 2005 ocurre algo similar para ambos métodos. En Ridge, los coeficientes tienden a acercarse a cero cuando las penalizaciones son muy elevadas, aunque sin llegar a ser exactamente cero. En cambio, en el caso de LASSO, algunos coeficientes sí terminan tomando el valor cero. De igual manera que en el gráfico anterior, puede observarse que ciertos coeficientes oscilan siempre alrededor de cero independientemente del nivel de penalización, por lo que no parecerían ser variables particularmente relevantes dentro del modelo.

2. Penalidad óptima por Cross-validation y visualización

Primero, mencionemos las penalidades seleccionadas según tanto para 2025 como 2005.

Para la muestra de 2025, en el caso de Ridge encontramos que se selecciono el λ 0.10000 como la penalidad optima, mientras que para LASSO selecciono λ 1.00000 como el optimo.

Ahora bien, para 2005 coincidieron los dos métodos en seleccionar 1.00000 como penalidad optima.

Los siguientes boxplots son el resultado de lo pedido en el ejercicio:




Figure 3: Boxplots generados para 2025




Figure 4: Boxplots generados para 2005

3. Estimación con λ^{cv} y comparación de coeficientes

Utilizando los λ^{cv} óptimos seleccionados en el ítem anterior — $\lambda = 1,0000$ para L1 y $\lambda = 0,1000$ para L2—, se estimaron tres modelos de regresión logística sobre $\mathbf{X}_{\text{train}}$ de la muestra 2025, todos sin intercepto: uno sin penalidad, uno con regularización L1 (LASSO) y uno con regularización L2 (Ridge). La Tabla 1 presenta los coeficientes estimados para cada variable bajo los tres esquemas.

Table 1: Comparación de coeficientes: sin penalidad, L1 y L2 (EPH 2025, sin intercepto)

Variable	Sin penalidad	L1 ($\lambda = 1,0000$)	L2 ($\lambda = 0,1000$)
CH06	0.2618	0.0000	0.1169
edad2	-0.4900	-0.2162	-0.3415
educ	0.0598	0.0309	0.0468
ingreso_total_familiar	0.2817	0.1343	0.1768
ix_tot	-0.0850	-0.0142	-0.0577
horastrab	0.0651	0.0420	0.0600
CH04	-2.6044	-2.1902	-2.3571
PP07H	-16.7062	-9.9584	-10.4440
PP03C	-4.4747	-3.5507	-3.8380
CAT_OCUP	3.1424	2.5638	2.7645
CH07	-0.6315	-0.5437	-0.5829

Los coeficientes regularizados son, en valor absoluto, **menores** que los del logit sin penalidad en todos los casos, lo cual refleja el efecto esperado de la regularización: al penalizar el tamaño de los coeficientes, el modelo los encoge hacia cero introduciendo algo de sesgo pero reduciendo la varianza y mejorando la generalización fuera de muestra.

El encogimiento es más pronunciado bajo L1 que bajo L2. Esto se debe a que LASSO penaliza el valor absoluto de los coeficientes, generando soluciones *sparse*, mientras que Ridge penaliza el cuadrado y distribuye la penalidad de forma más uniforme entre todas las variables.

En cuanto a la eliminación de variables, L1 asignó coeficiente exactamente igual a cero a **CH06** (edad lineal), lo que sugiere que, dada la presencia de **edad2** en la matriz X, la edad en niveles no aporta información adicional bajo este nivel de penalización. La penalidad L2, en cambio, **no eliminó ninguna variable**: Ridge puede encoger coeficientes pero nunca llevarlos exactamente a cero, por lo que todas las variables permanecen en el modelo.

B. Herramientas de IA y reflexión final.

1.

ChatGPT:

<https://chatgpt.com/share/6a174b5f-4ffc-83e9-b8d1-c21182821d83>

<https://chatgpt.com/share/6a174b73-11c0-83e9-ac32-60e3d2651aeb>

Cloude:

<https://claude.ai/share/a308f488-ed20-4f91-a0b1-66ba34d0c65c>

2.

Como en otros trabajos prácticos mencionados, el uso de estas herramientas nos permitió tanto para corregir códigos hechos, encaminarnos mejor con respecto a la interpretación de los ejercicios y tanto como para la elaboración del archivo overleaf a la hora de querer pasar algunos textos hechos en python hacia este archivo.

3.

Aproximadamente nos llevo entre 7 y 8 horas la realización del trabajo práctico.