



Universidad de
SanAndrés

Big Data

Trabajo Práctico N°5

Otoño 2026

Lucas Gael Chandia, Mateo Lopez Olaciregui

Fecha de entrega: 12 de Junio de 2026

A. Árboles

1)

Primero, veamos el error de clasificación como fue cambiando en base a los valores de α utilizados en `ccp_alpha`:




Figure 1: Evolución de error de clasificación

Se puede observar que para el α óptimo se produce la caída más pronunciada de el error de clasificación. Para los siguientes valores, el error de clasificación fluctúa entre 0.14 y 0.13, subiendo y bajando entre esos valores de manera aproximada.

Justamente el parámetro de `ccp_alpha` nos permite controlar que tan complejo puede ser un árbol resolviendo el trade-off sesgo-varianza. Mientras que un árbol sin podar capturaría ruido de la muestra de 2025 (overfitting), el valor óptimo de $\alpha = 0.00327$ minimiza el error de testeo estimado, eliminando ramas que no contribuyen a la capacidad predictiva general. Las fluctuaciones observadas para valores mayores de α indican que el modelo empieza a perder información relevante, tendiendo hacia el underfitting.




Figure 2: Árbol de informalidad 2025

El árbol obtenido confirma la relevancia de la cobertura de salud (CH08) y los aportes jubilatorios (PP07A) como los principales determinantes de la condición de actividad. El hecho de que el primer corte sea sobre CH08 y que PP07A sea el predictor con mayor importancia relativa resalta que la informalidad en la base 2025 sigue una estructura segmentada por el acceso a la seguridad social. Asimismo, se observan nodos terminales de informalidad con un índice de Gini de 0.0, lo que demuestra la alta capacidad del modelo para identificar perfiles 'puros' de vulnerabilidad laboral.

2)




Figure 3: Visualización del árbol podado por cross-validation

En el Panel A, se observa que la variable raíz es la cobertura de salud (CH08). Esto indica que el acceso a una obra social es el determinante principal para separar inicialmente a los trabajadores formales de los informales. El árbol identifica un camino hacia la informalidad absoluta: aquellos individuos que no cuentan con cobertura propia o de terceros ($CH08 > 2.5$) y que además no realizan aportes jubilatorios ($PP07A \leq 0.5$) son clasificados como informales en un nodo completamente puro, con un índice de Gini de 0.0.

En cuanto al Panel B, los resultados muestran que la variable con mayor peso es la condición de aportes (PP07A), seguida por el código de ocupación (PP04B_COD) y la cobertura de salud. Esto sugiere que las características estructurales de la inserción laboral y la seguridad social dominan la capacidad predictiva del modelo. Por el contrario, variables como el sexo (CH04), el ingreso per cápita familiar (IPCF) y la edad al cuadrado muestran una importancia marginal, lo que implica que aportan poca información adicional una vez controlada la situación de los aportes y la salud.

Respecto a LASSO, que fue lo realizado en el tp anterior, la diferencia clave es que utilizamos un set más pequeño de variables se omitieron las dos variables más importantes que resultaron de este método, que son CH08 y PP07A. Si se puede apreciar, por ejemplo que la variable como CH04 tanto como en LASSO como en este caso tiene una importancia baja, por lo que para ese caso si se coincidió. Esto también para IPCF paso.

B. Comparación entre métodos

3. Comparación entre métodos

Los tres modelos lineales (logit sin penalidad, LASSO y Ridge) arrojan resultados idénticos: $accuracy = 0,766$, $F1 = 0,688$ y $AUC = 0,828$. La regularización apenas modifica los coeficientes con variables ya depuradas. El KNN mejora el $accuracy$ (0,797) pero cae en $recall$ (0,571), detectando peor a los informales. El CART domina en todas las dimensiones: $accuracy = 0,864$ ($1 - accuracy = 0,136$), $F1 = 0,779$ y $AUC = 0,906$, con su curva ROC por encima del resto en todo el rango (Figura ??).

Existe un trade-off entre interpretabilidad y performance, pero el CART lo resuelve favorablemente: predice mejor y su estructura de reglas binarias es más comunicable que los coeficientes del logit o la lógica del KNN. La reducción del error de clasificación de 0,234 (modelos lineales) a 0,136 (CART) confirma que el método no lineal aporta una mejora sustantiva.

4. Asignación de recursos escasos

Con recursos limitados, lo relevante no es el $accuracy$ a umbral 0,5 sino la capacidad de ordenar a la población por riesgo de informalidad, capturada por el AUC . La Figura ?? muestra que, asistiendo al 30% de la población con mayor probabilidad predicha, el CART captura el 73,7% de los informales reales frente al 64,4% de todos los demás modelos. La curva del CART domina en todo el rango de presupuestos.

Nuestra respuesta cambia respecto del umbral fijo: aunque a $p > 0,5$ los modelos lineales tienen mayor *recall* (0,771 vs. 0,712), bajo restricción presupuestaria lo determinante es el ordenamiento. **Concluimos que el CART es el modelo preferible para dirigir el programa**, combinando el mejor poder de focalización ($AUC = 0,906$) con una estructura transparente y comunicable.

C. Herramientas de IA y reflexión final.

1)

Claude: <https://claude.ai/share/7b704296-ee44-4950-946c-7e9d46868920>

ChatGPT: <https://chatgpt.com/share/6a2c1a5d-5258-83e9-901d-d76c65f80728>

2)

Como en tps anteriores, el uso de las inteligencias artificiales los reservamos a correcciones de códigos, dado a que aquí se nos presento complicaciones con la utilización de ciertas variables que nos llevo a modificar/incluir nuevas variables dentro de nuestra matriz X.

3)

Aproximadamente entre los dos integrantes de nuestro grupo, nos llevo un total de 6-7 horas en completarlo todo, más que nada por tener que corregir algunas cosas ya mencionadas.